ESCUELA POLITÉCNICA SUPERIOR DE TECNOLOGÍA Y CIENCIA



Grado en Ingeniería Robótica e Inteligencia Artificial

PLANIFICACIÓN DE LA DOCENCIA UNIVERSITARIA

GUÍA DOCENTE

FUNDAMENTOS DE APRENDIZAJE AUTOMÁTICO

1. DATOS DE IDENTIFICACIÓN DE LA ASIGNATURA

Título:	Grado en Ingeniería Robótica e Inteligencia Artificial
Facultad:	ESCUELA POLITÉCNICA SUPERIOR DE TECNOLOGÍA Y CIENCIA
Departamento/Instituto:	
Módulo:	Sistemas inteligentes
Denominación de la asignatura:	Fundamentos de aprendizaje automático
Código:	88027
Curso:	3º
Año Académico:	2026-2027
Semestre:	2º semestre
Tipo de asignatura (básica, obligatoria u optativa):	Obligatoria
Créditos ECTS:	6
Modalidad/es de enseñanza:	Presencial
Lengua vehicular:	Castellano
Equipo docente:	Profesor/a: ENRIQUE DE MIGUEL AMBITE Tfno.: 91 815 31 31 Email: enrique.demiguel@ucjc.edu
Página web: www.ucjc.edu	

2. REQUISITOS PREVIOS

Esenciales:
Los específicos de la titulación
Aconsejables:
Conviene haber cursado Estadística, Álgebra Lineal, Fundamentos de Programación y Cálculo y Métodos Numéricos. También es recomendable tener conocimientos en Estructura de Datos y Fundamentos de Inteligencia Artificial.

3. SENTIDO Y APORTACIONES DE LA ASIGNATURA AL PLAN DE ESTUDIOS

Campo de conocimiento al que pertenece la asignatura.
Informática
Relación de interdisciplinariedad con otras asignaturas del currículum.
Esta asignatura se relaciona principalmente con Estadística, Álgebra Lineal, Fundamentos de Programación y Estructura de Datos, ya que el aprendizaje automático depende del procesamiento de grandes volúmenes de datos y de la aplicación de modelos matemáticos y algorítmicos. Además, tiene relación con Introducción a la Inteligencia Artificial, ya que el aprendizaje automático es una de las áreas más relevantes dentro de la IA. Conocer Cálculo y Métodos Numéricos también es útil para la implementación y optimización de algoritmos de aprendizaje automático.
Aportaciones al plan de estudios e interés profesional de la asignatura.
CN1 - Comprender los fundamentos físicos y matemáticos en los que se basa la robótica, identificando las propiedades físicas básicas de los dispositivos implicados en la robótica, así como los elementos matemáticos básicos que son necesarios para diseñar sistemas robóticos. CN10 - Conocer los fundamentos, conceptos y paradigmas de la Inteligencia Artificial y saber explicar sus elementos y procesos en el desarrollo de aplicaciones inteligentes, así como conocer las bases teóricas del aprendizaje automático y la tipología de técnicas y métodos de aprendizaje automático, y saber explicar su papel e integración en aplicaciones robóticas.

4. COMPETENCIAS QUE DESARROLLA LA MATERIA

4.1 Competencias genéricas (CG) y transversales (CT)

CG1 y CT1 - No procede

4.2 Competencias específicas (CE)

CE1 - No procede

5. RESULTADOS DE APRENDIZAJE

5.1 Resultados de aprendizaje relacionados con las competencias genéricas (CG) y transversales (CT)

H6 - Experimentar con diferentes algoritmos, y combinaciones de los mismos en el entrenamiento, evaluación y composición de elementos orientados a la producción de componentes de Inteligencia Artificial.

C7 - Aplicar las técnicas más adecuadas de la Inteligencia Artificial, y particularmente, del Aprendizaje Automático, a la realización de tareas específicas en la percepción, el control, la navegación y la coordinación de robots o sistemas con elementos robóticos, y evaluar su

rendimiento y los condicionantes de su operación en entornos donde pueden interactuar con personas.

5.2 Resultados de aprendizaje relacionados con las competencias específicas (CE)

CE1 - No procede

6. CONTENIDOS

Fundamentos, conceptos y paradigmas de la Inteligencia Artificial y bases teóricas del aprendizaje automático, incluyendo la tipología de técnicas y métodos y su integración en aplicaciones robóticas e informáticas. Contenidos específicos: aprendizaje supervisado (regresión y clasificación), aprendizaje no supervisado (agrupamiento y reducción de dimensionalidad) y entrenamiento, evaluación y supervisión de modelos (funciones de pérdida, generalización, sobreajuste, validación cruzada, selección de modelos y métricas).

7. CRONOGRAMA

Semana 1. Introducción a la IA y al aprendizaje automático

Conceptos básicos de inteligencia artificial y aprendizaje automático. Paradigmas y tipología de métodos. Papel del aprendizaje automático en aplicaciones robóticas e informáticas. Ejemplos en percepción, control, navegación y coordinación.

Semana 2. Datos y planteamiento de problemas

Tipos de variables y de problemas (regresión, clasificación, agrupamiento). Conjuntos de entrenamiento, validación y prueba. Calidad de los datos y posibles fuentes de sesgo.

Semana 3. Preparación y exploración de datos

Análisis exploratorio. Tratamiento de valores ausentes y atípicos. Codificación de variables categóricas. Normalización y estandarización. Selección inicial de características.

Semana 4. Fundamentos matemáticos y evaluación de modelos

Repaso aplicado de álgebra lineal, probabilidad y estadística. Funciones de pérdida. Error de entrenamiento y generalización. Sobreajuste y subajuste. Validación cruzada.

Semana 5. Aprendizaje supervisado: regresión

Regresión lineal simple y múltiple. Mínimos cuadrados. Interpretación de coeficientes. Métricas de evaluación (MAE, MSE, R^2). Práctica guiada con datos.

Semana 6. Aprendizaje supervisado: clasificación (I)

Clasificación binaria y multiclase. Regresión logística. Frontera de decisión. Matriz de confusión. Exactitud, precisión, exhaustividad, F1.

Semana 7. Aprendizaje supervisado: clasificación (II)
k vecinos más próximos. Árboles de decisión. Criterios de división, profundidad y riesgo de sobreajuste. Comparación experimental de modelos.
Semana 8. Evaluación continua 1 y consolidación
Prueba presencial escrita sobre fundamentos, preparación de datos, regresión y clasificación. Corrección comentada y análisis de errores.
Semana 9. Métodos de conjunto y bosques aleatorios
Bagging y boosting. Bosques aleatorios. Importancia de características. Comparación con árboles individuales en tareas de clasificación y regresión.
Semana 10. Máquinas de vectores soporte y otros clasificadores
Separación lineal, márgenes y regularización. Uso de kernels. Comparación con otros métodos en problemas de percepción y clasificación de patrones.
Semana 11. Aprendizaje no supervisado y agrupamiento
Fundamentos del aprendizaje no supervisado. Medidas de similitud y distancia. Algoritmo k-means. Selección del número de grupos.
Semana 12. Agrupamiento jerárquico y evaluación de clusters
Métodos aglomerativos. Dendrogramas. Evaluación interna de agrupamientos (p. ej., coeficiente de silueta). Aplicación a datos de sensores o navegación.
Semana 13. Reducción de dimensionalidad y evaluación continua 2
Análisis de componentes principales (PCA). Visualización de datos multidimensionales. Segunda prueba presencial escrita sobre aprendizaje no supervisado y evaluación de modelos.
Semana 14. Diseño experimental, buenas prácticas y ética
Comparación rigurosa de modelos, selección de hiperparámetros, reproducibilidad y prevención de fugas de información. Sesgos, privacidad, transparencia y uso responsable de la IA en entornos con personas.
Semana 15. Integración y presentación de resultados
Caso integrador: preparación de datos, entrenamiento, evaluación y análisis de un modelo aplicado a percepción, control o navegación. Presentación de resultados y discusión de alternativas.

Nota: La distribución expuesta en esta tabla tiene un carácter general y orientativo, se ajustará a las características y circunstancias de cada curso académico y grupo clase.

8. MODALIDADES ORGANIZATIVAS Y MÉTODOS DE ENSEÑANZA

Clases teórico-prácticas 36 h
Talleres/Laboratorios 24 h

Tutorías 6 h
Trabajo individual/en grupo 80 h
Examen final 4 h

9. SISTEMA DE EVALUACIÓN

Examen final (60%): prueba escrita presencial sobre la totalidad del temario, con parte teórica y parte de resolución de problemas prácticos de aprendizaje automático.
Evaluación continua — prácticas, ejercicios y trabajos entregables (10%): entregables prácticos centrados en preparación de datos, modelos supervisados y no supervisados, evaluación comparativa de modelos y proyecto integrador de pipeline de percepción–modelo–inferencia.
Evaluación continua — pruebas presenciales en aula (orales o escritas) (30%): defensas presenciales de las prácticas y una prueba de control intermedia (semana 8 aprox.) sobre fundamentos, entrenamiento y evaluación de modelos de aprendizaje automático.

CONSIDERACIONES GENERALES ACERCA DE LA EVALUACIÓN:

CONSIDERACIONES GENERALES ACERCA DE LA EVALUACIÓN:
La evaluación de la asignatura, tanto en la convocatoria ordinaria como en la extraordinaria, tiene en cuenta la evaluación continua de cada alumno, incluyendo la asistencia participativa a las clases, la realización de los trabajos y proyectos individuales y cooperativos y la realización de los exámenes, con una valoración respecto a la calificación final en los porcentajes indicados en el cuadro anterior.
A su vez, a elección del alumno y bajo la supervisión del profesor, se podrá celebrar la convocatoria extraordinaria sólo examen en la cual , el estudiante podrá elegir el método de evaluación correspondiente a la evaluación continua o, bien, la aplicación de la calificación obtenida únicamente en el examen de convocatoria extraordinaria.
Según el artículo 12.2. de la Normativa académica de evaluaciones, calificaciones y reclamaciones de la UCJC, la asistencia a las sesiones presenciales de clase es imprescindible para superar la asignatura. Si el alumno falta a más del 20% de las clases, éste perderá la evaluación continua que, en cualquier caso, tendrá una ponderación superior a la evaluación final.
La asistencia a clase con puntualidad es obligatoria y será controlada. Todos los alumnos deberán justificar documentalmente al profesor cualquier falta de asistencia a clase. De igual

modo, es obligatoria la asistencia a las actividades extraescolares que se indiquen por los profesores.

Todos los alumnos deberán realizar y entregar en tiempo y forma todos los trabajos y proyectos individuales y cooperativos indicados durante el curso, independientemente de la Convocatoria o Curso en el que estén matriculados los alumnos. Las faltas de ortografía supondrán una importante reducción de la nota.

En el caso de intento de plagio o realización fraudulenta de exámenes, trabajos, etc., se atenderá al artículo 3.3. de la Normativa académica de evaluaciones, calificaciones y reclamaciones de la UCJC, según el cual "La realización fraudulenta de un examen implicará la calificación de suspenso (nota numérica 0) y la expulsión del examen, con independencia de las sanciones disciplinarias que pudieran derivarse tras la comunicación de la comisión de dicha falta al Defensor Universitario".

10. BIBLIOGRAFÍA / WEBGRAFÍA

Bibliografía básica

Bibliografía básica

Géron, A. (2022). Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems (3rd ed.). O'Reilly Media. Disponible en plataforma O'Reilly de la UCJC.

Hastie, T., Tibshirani, R., & Friedman, J. (2009). The elements of statistical learning: Data mining, inference, and prediction (2nd ed.). Springer. https://doi.org/10.1007/978-0-387-84858-7

Disponible en elibro (acceso institucional UCJC).

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). An introduction to statistical learning: With applications in R (2nd ed.). Springer. https://doi.org/10.1007/978-1-0716-1418-1

Disponible en elibro (acceso institucional UCJC).

Bibliografía complementaria

Bishop, C. M. (2006). Pattern recognition and machine learning. Springer.

Disponible en elibro (acceso institucional UCJC).

Kelleher, J. D., Mac Namee, B., & D'Arcy, A. (2020). Fundamentals of machine learning for predictive data analytics: Algorithms, worked examples, and case studies (2nd ed.). MIT Press.

Kuhn, M., & Johnson, K. (2013). Applied predictive modeling. Springer. https://doi.org/10.1007/978-1-4614-6849-3

Disponible en elibro (acceso institucional UCJC).

McKinney, W. (2022). Python for data analysis: Data wrangling with pandas, NumPy, and Jupyter (3rd ed.). O'Reilly Media. Disponible en plataforma O'Reilly de la UCJC.

Raschka, S., Liu, Y., & Mirjalili, V. (2022). Machine learning with PyTorch and Scikit-Learn: Develop machine learning and deep learning models with Python. Packt Publishing.

VanderPlas, J. (2022). Python data science handbook: Essential tools for working with data (2nd ed.). O'Reilly Media. Disponible en plataforma O'Reilly de la UCJC.

Recursos de libre acceso (complementarios)

Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep learning. MIT Press. http://www.deeplearningbook.org/

Murphy, K. P. (2022). Probabilistic machine learning: An introduction. MIT Press. https://probml.github.io/

Scikit-learn developers. (s. f.). Scikit-learn: Machine learning in Python. https://scikit-learn.org/

Bibliografía complementaria

El profesor aportará textos para su comentario a lo largo del curso, disponible en el campus electrónico de la asignatura

Nota: Las referencias bibliográficas citadas no constituyen un listado cerrado; cada profesor podrá añadir recursos que considere pertinentes según las características e intereses del grupo.

11. OBSERVACIONES

En el caso de que se produzca alguna de las conductas tipificadas en el Régimen jurídico y procedimiento sancionador del estudiante universitario, el tutor debe ponerlo en conocimiento del Director del título y del Coordinador de estudiantes, quienes decidirán la sanción correspondiente contemplada en dicho reglamento.
En el caso de intento de plagio o realización fraudulenta de estancias, trabajos, etc. se atenderá al artículo 3.3. de la Normativa académica de evaluaciones, calificaciones y reclamaciones.